



**FACULTAD DE CIENCIAS MATEMÁTICAS Y FÍSICA**

**Carrera**

Ciencias de datos e Inteligencia Artificial

**Asignatura**

Aprendizaje Automático

**Estudiantes**

Andres Steven Velez Landaverea

**Docente**

Ing. Darwin Rodríguez Merchán, MSc

**Ciclo**

2026 – 2027 CI

# **Análisis Discriminante Lineal (LDA) y Análisis Discriminante Cuadrático (QDA)**

## **Introducción**

### **¿Qué es el análisis discriminante?**

El análisis discriminante es un conjunto de técnicas estadísticas de clasificación supervisada que buscan asignar una observación a una de varias categorías o clases conocidas de antemano, a partir de un conjunto de variables predictoras medidas sobre esa observación. En lugar de modelar directamente la probabilidad de pertenecer a una clase en función de las variables predictoras (como hace la regresión logística), el análisis discriminante parte de modelar cómo se distribuyen las variables predictoras dentro de cada clase, y luego aplica el teorema de Bayes para invertir esa relación y obtener la probabilidad de que una observación pertenezca a cada clase.

Dentro de esta familia de técnicas, los dos enfoques más utilizados son el Análisis Discriminante Lineal (LDA) y el Análisis Discriminante Cuadrático (QDA), que se diferencian principalmente en el supuesto que hacen sobre la forma de la matriz de covarianza de cada clase.

### **¿Cuál es el objetivo de un modelo discriminante?**

El objetivo central de un modelo discriminante es construir una regla de decisión que permita separar de la mejor manera posible las distintas clases presentes en los datos, minimizando los errores de clasificación. Para lograrlo, el modelo estima, a partir de los datos de entrenamiento, la distribución de las variables predictoras dentro de cada clase (típicamente asumiendo una distribución normal multivariante) y las probabilidades previas de cada clase. Con esa información construye funciones discriminantes que, evaluadas sobre una nueva observación, indican a qué clase es más probable que pertenezca. El resultado final es una frontera de decisión en el espacio de las variables predictoras que separa las regiones asociadas a cada clase.

### **¿Qué diferencia existe entre clasificación y regresión?**

La clasificación y la regresión son los dos grandes tipos de problemas de aprendizaje supervisado, y se diferencian por la naturaleza de la variable objetivo (o variable de respuesta) que se busca predecir. En un problema de regresión, la variable objetivo es continua o numérica (por ejemplo, el precio de una vivienda o la temperatura del día siguiente), y el modelo busca estimar un valor numérico lo más cercano posible al valor real. En un problema de clasificación, en cambio, la variable objetivo es categórica, es decir, toma valores dentro de un conjunto finito de clases o etiquetas (por ejemplo, si un

correo es spam o no, o a qué cultivar de uva pertenece un vino), y el modelo busca asignar cada observación a la clase correcta.

LDA y QDA son técnicas de clasificación: aunque internamente construyen funciones discriminantes de tipo numérico (lineales o cuadráticas), su salida final es una etiqueta de clase, no un valor continuo.

## **Análisis Discriminante Lineal (LDA)**

### **¿Qué es el Análisis Discriminante Lineal (LDA)?**

El Análisis Discriminante Lineal es un método de clasificación supervisada que asume que las observaciones de cada clase provienen de una distribución normal multivariante, y que todas las clases comparten exactamente la misma matriz de covarianza, difiriendo únicamente en su vector de medias. Bajo este supuesto, al aplicar el teorema de Bayes para calcular la probabilidad de que una observación pertenezca a cada clase, los términos cuadráticos asociados a la covarianza se cancelan entre clases, y el resultado es una función discriminante lineal en las variables predictoras.

### **¿Cuáles son sus supuestos estadísticos?**

- Cada clase sigue una distribución normal (gaussiana) multivariante en el espacio de las variables predictoras.
- Todas las clases comparten la misma matriz de covarianza (homocedasticidad multivariante).
- Las observaciones son independientes entre sí.
- Las variables predictoras no presentan colinealidad extrema, ya que esto puede hacer que la matriz de covarianza compartida sea casi singular y difícil de invertir.

### **¿Qué significa que las clases compartan la misma matriz de covarianza?**

Que las clases compartan la misma matriz de covarianza significa que, aunque cada clase tiene su propio centro (vector de medias), la forma, orientación y dispersión de la nube de puntos alrededor de ese centro es igual para todas las clases. Gráficamente, si se dibujaran las elipses de densidad de cada clase, todas tendrían el mismo tamaño, forma y orientación, solo desplazadas hacia distintos centros. Este supuesto es lo que le permite a LDA usar una única matriz de covarianza estimada combinando (o "agrupando") las observaciones de todas las clases, en lugar de estimar una matriz distinta por cada una.

### **¿Cómo construye la función discriminante?**

LDA parte de estimar, para cada clase  $k$ , un vector de medias y la probabilidad previa de esa clase, además de una matriz de covarianza común calculada a partir de todas las observaciones (independientemente de su clase). Usando el teorema de Bayes y asumiendo densidades normales con covarianza compartida, se puede demostrar que la clase con mayor probabilidad posterior es aquella que maximiza una función discriminante lineal de la forma  $\delta_k(x)$ , construida a partir del producto entre la inversa de la matriz de covarianza compartida, el vector de medias de la clase y el vector de variables predictoras  $x$ , más un término constante que depende de la probabilidad previa de la clase. Una nueva observación se clasifica en la clase  $k$  para la cual esta función lineal  $\delta_k(x)$  toma el valor más alto.

### **¿Por qué la frontera de decisión es lineal?**

La frontera de decisión entre dos clases es el conjunto de puntos  $x$  para los cuales sus funciones discriminantes son iguales, es decir,  $\delta_i(x) = \delta_j(x)$ . Como ambas funciones discriminantes son lineales en  $x$  (por compartir la misma matriz de covarianza), su diferencia también es una función lineal de  $x$ , y el conjunto de puntos donde esa diferencia se anula corresponde a un hiperplano (una recta en dos dimensiones, un plano en tres dimensiones, y así sucesivamente). Por esta razón, las fronteras de decisión de LDA siempre son lineales, sin importar cuántas clases o variables existan.

### **¿Cuáles son sus ventajas?**

- Es un modelo simple, con pocos parámetros a estimar (solo una matriz de covarianza compartida), por lo que suele generalizar bien incluso con muestras de tamaño moderado.
- Es computacionalmente eficiente tanto para entrenar como para predecir.
- Produce fronteras de decisión interpretables y permite además usarse como técnica de reducción de dimensionalidad, proyectando los datos sobre las direcciones que mejor separan las clases.
- Suele ser robusto cuando el número de observaciones es pequeño en relación con el número de variables, en comparación con métodos que requieren estimar más parámetros.

### **¿Cuáles son sus limitaciones?**

- El supuesto de covarianza compartida entre clases rara vez se cumple exactamente en datos reales, lo que puede sesgar las fronteras de decisión.
- Al ser un modelo lineal, no puede capturar relaciones curvas o interacciones complejas entre variables y clases.
- Es sensible a valores atípicos (outliers), que pueden distorsionar la estimación de las medias y de la matriz de covarianza compartida.
- Su desempeño se degrada si las variables predictoras están muy correlacionadas entre sí (colinealidad), ya que la matriz de covarianza puede volverse casi singular.

### **¿En qué problemas suele utilizarse?**

LDA se utiliza ampliamente en problemas de reconocimiento de patrones y bioinformática (por ejemplo, clasificación de tipos de cáncer a partir de datos de expresión génica), en reconocimiento facial y de voz como técnica de reducción de dimensionalidad previa a la clasificación, en diagnóstico médico cuando se dispone de pocas observaciones por clase, en clasificación de textos, y en general en cualquier escenario donde se necesite un modelo simple, rápido e interpretable, y exista evidencia (o al menos no evidencia en contra) de que las clases comparten una estructura de dispersión similar.

## **Análisis Discriminante Cuadrático (QDA)**

### **¿Qué es el Análisis Discriminante Cuadrático?**

El Análisis Discriminante Cuadrático es una generalización de LDA que relaja el supuesto de covarianza compartida entre clases: en QDA, cada clase puede tener su propia matriz de covarianza. Al igual que en LDA, se asume que las observaciones de cada clase siguen una distribución normal multivariante, pero ahora se permite que la forma, orientación y dispersión de esa distribución varíe de una clase a otra.

### **¿Cuáles son sus supuestos?**

- Cada clase sigue una distribución normal multivariante.
- Cada clase puede tener su propia matriz de covarianza (no se asume igualdad entre clases).
- Las observaciones son independientes entre sí.
- Se requiere un número suficiente de observaciones por clase para estimar de forma confiable una matriz de covarianza completa por cada una, especialmente cuando el número de variables predictoras es alto.

### **¿Por qué cada clase posee una matriz de covarianza distinta?**

QDA no combina las observaciones de todas las clases para estimar una única matriz de covarianza, sino que utiliza únicamente las observaciones de la clase  $k$  para estimar la matriz de covarianza de esa clase. Esto permite capturar situaciones reales en las que unas clases están más dispersas o tienen una orientación distinta que otras; por ejemplo, una clase cuyas observaciones varían mucho en una variable y poco en otra, frente a otra clase con el patrón de dispersión inverso. El costo de esta flexibilidad es que se deben estimar tantas matrices de covarianza como clases existan, lo que incrementa considerablemente el número de parámetros del modelo.

### **¿Por qué la frontera es cuadrática?**

Al no compartir la matriz de covarianza entre clases, los términos cuadráticos de la función discriminante de Bayes (que dependen de la inversa de la matriz de covarianza de cada clase) ya no se cancelan al comparar dos clases, como sí ocurría en LDA. Por lo tanto, la función discriminante  $\delta_k(x)$  de QDA contiene términos cuadráticos en  $x$ , y la frontera de decisión entre dos clases (el conjunto de puntos donde  $\delta_i(x) = \delta_j(x)$ ) resulta ser una superficie cuadrática: una curva en dos dimensiones (por ejemplo, una parábola, elipse o hipérbola), o una superficie cuadrática de mayor dimensión en el caso general.

### **¿Qué ventajas presenta frente a LDA?**

- Puede adaptarse mejor a datos donde las clases tienen dispersiones o formas claramente distintas, ya que no impone una única forma de covarianza para todas.
- Al ser un modelo más flexible, puede lograr un menor error de clasificación cuando el supuesto de covarianza compartida de LDA no se cumple en la realidad.
- Sigue basándose en un marco probabilístico claro (densidades normales y teorema de Bayes), lo que facilita su interpretación en términos de verosimilitud.

### **¿Qué desventajas tiene?**

- Requiere estimar muchos más parámetros que LDA (una matriz de covarianza completa por cada clase), lo que aumenta el riesgo de sobreajuste cuando se dispone de pocas observaciones por clase.
- Es computacionalmente más costoso, especialmente cuando el número de variables predictoras es grande, ya que cada matriz de covarianza debe invertirse por separado.
- Puede volverse inestable o generar matrices de covarianza casi singulares si alguna clase tiene muy pocas observaciones en relación con el número de variables.
- Al producir fronteras curvas, su interpretación geométrica es menos directa que la de LDA.

### **¿Qué tipo de conjuntos de datos favorecen su utilización?**

QDA tiende a ser más adecuado cuando se dispone de un número grande de observaciones por clase (para poder estimar de forma confiable una matriz de covarianza distinta por cada una), y cuando existe evidencia previa (por ejemplo, mediante pruebas estadísticas de homogeneidad de varianzas o simplemente mediante visualización de los datos) de que las clases presentan estructuras de dispersión claramente diferentes entre sí. En esos escenarios, la flexibilidad adicional de QDA suele traducirse en una mejora real del desempeño frente a LDA, mientras que en datasets pequeños o con covarianzas similares entre clases, LDA suele ser preferible por su mayor estabilidad.

## Bibliografía

Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer.

Scikit-learn developers. (n.d.). Linear and quadratic discriminant analysis. In *Scikit-learn documentation*. [https://scikit-learn.org/stable/modules/lda\\_qda.html](https://scikit-learn.org/stable/modules/lda_qda.html) ([scikit-learn.org in Bing](#))